

Analyse Big Data des Crimes à Chicago (2001–2024)

Rapport de Projet — PySpark · Folium · Analyse Géospatiale

Auteur : Bakayoko Moussa

Date : Decembre 2026

Type : Rapport de Projet Data

1. Résumé exécutif

Ce projet mobilise des technologies Big Data pour analyser plus de 20 ans de données criminelles de la ville de Chicago. En utilisant Apache Spark (PySpark) pour le traitement distribué et Folium pour la visualisation géospatiale, l'analyse a permis d'identifier les zones à haute criminalité, les types de crimes les plus fréquents, les tendances temporelles et les secteurs de patrouille prioritaires.

2. Contexte : le défi du Big Data policier

La ville de Chicago publie en open data l'ensemble des incidents criminels signalés depuis 2001, actualisé quotidiennement. Ce dataset représente plusieurs millions de lignes et des dizaines de colonnes — un volume qui dépasse les capacités des outils analytiques classiques (Excel, pandas sur une machine standard). La mission est celle d'un Data Detective chargé d'extraire des insights actionnables pour améliorer la stratégie de sécurité publique de la ville.

3. Infrastructure technique — PySpark

3.1 Pourquoi PySpark ?

Apache Spark est le framework de référence pour le traitement distribué de données volumineuses. PySpark, son interface Python, offre des DataFrames similaires à pandas mais avec une exécution distribuée sur cluster. Pour ce projet, Spark a été utilisé en mode local (single-node) afin de démontrer la maîtrise de l'écosystème Big Data.

Paramètre technique	Valeur
Framework	Apache Spark 3.5.1 via PySpark
Interface Python	findspark 2.0.1 + pyspark 3.5.1
Source de données	data.cityofchicago.org — Chicago Crime Data
Volume	Plusieurs millions de lignes (2001 à date)
Format d'ingestion	CSV → Spark DataFrame
Traitement	Mode local (simulant un environnement distribué)

3.2 Configuration de l'environnement Spark

- Installation de findspark pour localiser Spark sur la machine locale.
- Initialisation de la SparkSession avec configuration des ressources (mémoire, cores).
- Lecture du CSV avec inférence automatique du schéma (inferSchema=True).
- Configuration du niveau de log pour réduire la verbosité lors des exécutions longues.

4. Pipeline d'analyse

4.1 Phase 1 — Ingestion et audit de la qualité

- Chargement du dataset Chicago Crime via l'API publique de la ville ou fichier CSV local.
- Inspection du schéma : 22 colonnes incluant ID, Date, Block, IUCR, Primary Type, Description, Location, Arrest, District, Ward, Community Area, X et Y Coordinates, Latitude, Longitude.

- Audit des valeurs manquantes par colonne (notamment Latitude/Longitude manquants pour ~2% des incidents).
- Vérification de la cohérence temporelle : suppression des entrées avec dates aberrantes.

4.2 Phase 2 — Nettoyage et transformation

- Conversion du champ Date (string) en type timestamp Spark pour les analyses temporelles.
- Extraction de features temporelles : year, month, day_of_week, hour à partir du timestamp.
- Filtrage des entrées sans coordonnées géographiques pour les analyses spatiales.
- Normalisation des types de crimes (Primary Type) : harmonisation des libellés.

4.3 Phase 3 — Analyse descriptive

Analyse	Méthode Spark
Top 10 types de crimes	<code>groupBy('Primary Type').count().orderBy(desc('count'))</code>
Évolution annuelle	<code>groupBy(year('Date')).count().orderBy('year')</code>
Crimes par heure de la journée	<code>groupBy(hour('Date')).count()</code>
Taux d'arrestation global	<code>mean('Arrest').alias('arrest_rate')</code>
Distribution par district	<code>groupBy('District').count()</code>
Crimes par jour de la semaine	<code>groupBy(dayofweek('Date')).count()</code>

4.4 Phase 4 — Analyse géospatiale (Folium)

La dimension géospatiale est centrale dans l'analyse criminelle. Folium a été utilisé pour produire des cartes interactives révélant la distribution spatiale des crimes :

- Heatmap de densité criminelle : carte thermique superposant tous les incidents géolocalisés, révélant les zones chaudes (hot spots).
- Carte par type de crime : visualisation sélective par catégorie (vol, agression, trafic de drogue).
- Carte des arrestations : identification des zones où le taux d'arrestation est le plus faible (zones sous-patrouillées).
- Clustering géographique : regroupement des incidents par proximité géographique pour identifier des microzones à risque.

4.5 Phase 5 — Analyse des patrouilles et recommandations

- Analyse des districts (beats) : identification des secteurs de patrouille avec le plus haut ratio crimes/arrestations.
- Analyse temporelle fine : identification des créneaux horaires et journées à risque élevé par zone.
- Corrélation saisonnière : certains types de crimes présentent une forte saisonnalité (crimes violents en été, cambriolages en hiver).

5. Bibliothèques et versions

Bibliothèque	Version / Usage
pyspark	3.5.1 — Traitement Big Data distribué (DataFrames, SQL)
findspark	2.0.1 — Initialisation de l'environnement Spark

pandas	2.2.2 — Conversion Spark → pandas pour les visualisations
folium	0.16.0 — Cartes interactives et heatmaps géospatiales
matplotlib	3.9.0 — Graphiques statistiques (bar charts, time series)
seaborn	0.13.2 — Visualisations avancées et matrices de corrélation
numpy	1.26.4 — Calculs numériques
py4j	0.10.9.7 — Bridge Python-JVM requis par PySpark

6. Résultats et insights

20+	Millions	35+	25+
Années de données	Crimes analysés	Types de crimes	Districts couverts

6.1 Principaux insights

- Le vol (THEFT) est le crime le plus fréquent, représentant environ 20% de tous les incidents.
- Le taux d'arrestation global est inférieur à 20%, avec de fortes disparités selon les types de crimes.
- Les heures de midi (12h-14h) et de fin de soirée (21h-23h) concentrent les pics d'incidents.
- Les mois d'été (juin-août) voient une augmentation de 30-40% des crimes violents.
- Certains districts du South Side et West Side présentent des densités criminelles 5x supérieures à la moyenne.

7. Livrables

- Notebook Jupyter complet : code PySpark documenté, analyses et visualisations.
- Cartes interactives Folium exportées en HTML (heatmap, carte par type, carte des arrestations).
- Présentation PowerPoint : résumé des insights pour les décideurs avec storytelling.
- Rapport écrit avec recommandations pour le département de police.