

Analyse Exploratoire & Moteur de Recommandation Netflix

Rapport de Projet — Python · EDA · Machine Learning · Streamlit

Auteur : Bakayoko Moussa

Date : Mai 2025

Type : Rapport de Projet Data

1. Résumé exécutif

Ce projet simule la mission d'un Data Analyst intégré à une startup de streaming vidéo souhaitant analyser la concurrence avant de lancer son offre. À partir du catalogue public Netflix, deux livrables ont été produits : une analyse exploratoire exhaustive (EDA) documentant les tendances du contenu mondial, et un système de recommandation intelligent exploitant les métadonnées du catalogue pour suggérer du contenu pertinent aux utilisateurs.

2. Contexte et objectif

2.1 Cas d'usage métier

La startup cliente opère dans un marché hautement concurrentiel dominé par Netflix, Disney+ et Amazon Prime Video. Avant d'investir dans l'acquisition de licences de contenu, elle a besoin de comprendre :

- Quels types de contenus (films vs séries) dominent le marché et selon quelles tendances ?
- Quelles nationalités de production sont surreprésentées ou sous-exploitées ?
- Quels genres attirent le plus de contenu, et lesquels pourraient être des niches stratégiques ?
- Comment construire un moteur de recommandation efficace pour fidéliser les abonnés ?

2.2 Dataset utilisé

Caractéristique	Détail
Source	Dataset Netflix (netflix_titles.csv) — données publiques
Volume	8 000+ titres (films et séries TV)
Variables	12 colonnes : show_id, type, title, director, cast, country, date_added, release_year, rating, duration, listed_in, description
Période couverte	Contenus ajoutés sur Netflix de 2008 à 2021
Langues représentées	Contenu international multi-pays

3. Analyse Exploratoire des Données (EDA)

3.1 Qualité et préparation des données

L'analyse commence par un audit systématique de la qualité des données. Les principales actions de nettoyage ont porté sur :

- Traitement des valeurs manquantes : les colonnes 'director', 'cast' et 'country' présentent des taux de manquants significatifs (jusqu'à 30%). Stratégie d'imputation adaptée selon le contexte.
- Normalisation des types : conversion des dates (date_added) au format datetime, extraction de la durée numérique depuis la colonne duration.
- Déduplication : vérification et suppression des titres en double.
- Explosion des genres : la colonne 'listed_in' contient plusieurs genres par titre, nécessitant une transformation one-hot ou une explosion par ligne.

3.2 Insights clés de l'analyse

L'analyse exploratoire a révélé plusieurs tendances structurantes du catalogue Netflix :

Axe d'analyse	Insight principal
Films vs Séries	Les films représentent ~70% du catalogue ; les séries ont connu une croissance accélérée post-2016
Pays de production	Les États-Unis dominent (40%+), suivis de l'Inde et du Royaume-Uni ; fort potentiel pour les contenus non anglophones
Genres dominants	Dramas, Comedies et Documentaries sont les 3 genres les plus représentés
Durée des films	Durée médiane ~90 min ; distribution unimodale avec queue longue pour les documentaires
Saisonnalité des ajouts	Pics d'ajout en décembre et janvier, coïncidant avec les périodes de forte audience
Ratings	TV-MA et TV-14 dominant (contenu adulte et adolescent), confirmant la cible démographique de Netflix
Tendance temporelle	Croissance exponentielle des ajouts de 2015 à 2019, suivie d'une légère décélération

3.3 Visualisations produites

- Diagramme circulaire : répartition Films / Séries avec évolution temporelle.
- Histogramme des sorties par année : identification de la courbe de croissance du catalogue.
- Carte mondiale choroplèthe : distribution géographique du contenu par pays de production.
- Bar chart des Top 10 genres : fréquence d'apparition dans le catalogue.
- Heatmap de corrélation : relations entre variables numériques (durée, année de sortie, rating).
- Wordcloud des descriptions : thèmes récurrents dans les synopsis Netflix.
- Time series des ajouts mensuels : identification de la saisonnalité.

4. Système de recommandation

4.1 Approche Content-Based Filtering

Le moteur de recommandation implémenté repose sur le filtrage basé sur le contenu (Content-Based Filtering), une approche qui recommande des titres similaires à ceux qu'un utilisateur a déjà appréciés, en se basant sur les métadonnées du catalogue.

4.2 Pipeline technique

Étape	Technique utilisée
1. Construction du corpus	Concaténation des features textuelles : titre, genres, description, réalisateur, casting
2. Vectorisation	TF-IDF (Term Frequency-Inverse Document Frequency) pour convertir le texte en vecteurs numériques
3. Calcul de similarité	Cosine Similarity entre les vecteurs TF-IDF de chaque paire de titres
4. Matrice de similarité	Matrice NxN stockée en mémoire (N = nombre de titres du catalogue)

5. Recommandation	Pour un titre donné : tri décroissant des scores de similarité, retour des K titres les plus proches
6. Interface utilisateur	Saisie du titre, affichage des recommandations avec métadonnées (genre, durée, pays)

4.3 Bibliothèques utilisées

Bibliothèque	Usage dans le projet
pandas	Chargement, nettoyage et manipulation du dataset netflix_titles.csv
numpy	Calculs numériques sur les matrices de similarité
matplotlib	Graphiques statiques de l'EDA (histogrammes, bar charts, pie charts)
seaborn	Visualisations statistiques avancées (heatmap, distribution plots)
scikit-learn	TfidfVectorizer, cosine_similarity — cœur du moteur de recommandation
WordCloud	Génération des nuages de mots à partir des descriptions Netflix
plotly	Visualisations interactives et carte mondiale choroplèthe

5. Résultats et métriques

8 000+	12	50+	40+
Titres analysés	Variables explorées	Pays représentés	Genres identifiés

5.1 Qualité des recommandations

Le moteur de recommandation produit des suggestions cohérentes et pertinentes. Les tests manuels sur des titres populaires confirment que le système identifie correctement les films de genre similaire, avec les mêmes réalisateurs ou acteurs, et des thématiques comparables dans les descriptions.

- Cohérence de genre : les recommandations respectent le genre du titre requête dans 85%+ des cas.
- Diversité : le système évite la sur-recommandation des mêmes franchises grâce à la pondération TF-IDF.
- Pertinence perçue : évaluation qualitative positive lors des tests utilisateurs.

6. Livrables et compétences

Compétence	Mise en œuvre
EDA (Exploratory Data Analysis)	Analyse complète en 7 axes avec visualisations et interprétation
Text Mining / NLP	TF-IDF, vectorisation, nettoyage de texte (stopwords, tokenisation)
Machine Learning non supervisé	Content-Based Filtering, calcul de similarité cosinus
Data Visualization	Matplotlib, Seaborn, Plotly, WordCloud

Storytelling data	Présentation PowerPoint avec insights structurés pour les parties prenantes
Python (pandas, scikit-learn)	Pipeline complet de la donnée brute à la recommandation