

Segmentation de la Clientèle par K-Means et ACP

Rapport de Projet — Python · Scikit-learn · Machine Learning non
supervisé

Auteur : Bakayoko Moussa

Date : Octobre 2024

Type : Rapport de Projet Data

1. Résumé exécutif

Ce projet répond à un besoin concret des équipes marketing : mieux connaître les clients pour allouer efficacement les ressources marketing et personnaliser la communication. En appliquant l'algorithme K-Means couplé à une Analyse en Composantes Principales (ACP), les clients ont été regroupés en segments homogènes et distincts, permettant d'adapter les actions commerciales à chaque profil.

2. Problématique métier

Une entreprise commerciale souhaitait améliorer l'efficacité de sa stratégie marketing en passant d'une approche 'one-size-fits-all' à une approche segmentée. Les données historiques des clients (comportements d'achat, fréquence, montants) constituaient un actif inexploité. L'enjeu était de transformer ces données brutes en segments actionnables pour les équipes marketing.

Problème	Solution apportée
Marketing indifférencié : mêmes messages pour tous les clients	Segmentation en K clusters avec profils distincts et actionnables
Méconnaissance des comportements clients	Analyse des patterns d'achat : fréquence, récence, montant (RFM)
Allocation inefficace du budget marketing	Priorisation des segments à haute valeur (champions, fidèles)
Données brutes inexploitées	Pipeline ML complet de la donnée brute aux segments interprétés

3. Données et préparation

3.1 Source et structure des données

Le projet repose sur un dataset clients contenant les données transactionnelles et comportementales nécessaires à la segmentation. Les variables couvrent les dimensions classiques du modèle RFM (Récence, Fréquence, Montant) ainsi que des informations démographiques et comportementales complémentaires.

3.2 Préparation des données

- Traitement des valeurs manquantes : imputation par médiane pour les variables numériques, mode pour les catégorielles.
- Détection et traitement des outliers : analyse des distributions, winsorisation à 95% pour les montants extrêmes.
- Encodage des variables catégorielles : one-hot encoding pour les variables nominales, ordinal encoding pour les variables ordinales.
- Normalisation (StandardScaler) : standardisation des features à moyenne 0 et écart-type 1, indispensable pour K-Means.
- Feature engineering : calcul des indicateurs RFM (Récence en jours, Fréquence en nombre d'achats, Monetary en montant total).

4. Méthodologie de segmentation

4.1 Algorithme K-Means

K-Means est un algorithme de clustering non supervisé qui partitionne les données en K groupes (clusters) en minimisant la somme des distances intra-cluster (inertie). L'algorithme itère jusqu'à convergence des centroïdes.

4.2 Détermination du nombre optimal de clusters

Deux méthodes complémentaires ont été utilisées pour choisir K :

- Méthode du coude (Elbow Method) : tracé de l'inertie en fonction de K. Le 'coude' identifie le point de diminution marginale des gains, suggérant K optimal.
- Score de silhouette : mesure la cohésion intra-cluster et la séparation inter-cluster. Un score proche de 1 indique une segmentation de qualité.

Les deux méthodes ont convergé vers le même nombre optimal de clusters, validant la robustesse de la segmentation.

4.3 Analyse en Composantes Principales (ACP)

L'ACP a été appliquée pour deux objectifs complémentaires :

- Réduction de dimensionnalité : projeter les données en 2D ou 3D pour la visualisation des clusters, tout en préservant la variance maximale.
- Amélioration de la segmentation : réduire le bruit et la redondance entre features avant l'application de K-Means (K-Means + ACP).
- Interprétation des axes : les composantes principales révèlent les dimensions latentes qui structurent les comportements clients.

Paramètre ACP	Valeur / Description
Composantes retenues	2 à 3 (selon variance expliquée cumulée)
Variance expliquée	> 70% sur les 2 premières composantes
Rotation	Pas de rotation (PCA classique)
Standardisation préalable	Oui — StandardScaler appliqué avant ACP

4.4 Interprétation des segments

Chaque cluster a été caractérisé par l'analyse de ses centroïdes et la distribution de ses membres. Les segments types identifiés dans ce type d'analyse sont :

Segment type	Profil comportemental
Champions	Achats récents, fréquents et de montant élevé — clients les plus précieux
Fidèles	Achats réguliers, montants modérés — base stable de l'entreprise
À risque	Anciens bons clients devenus inactifs — cibles de réactivation
Nouveaux clients	Premier achat récent, comportement encore indéfini
Hibernants	Longue inactivité, faible valeur historique — faible priorité

5. Bibliothèques et outils utilisés

Bibliothèque	Usage
pandas	Chargement et manipulation des données clients
numpy	Calculs numériques et opérations sur matrices
scikit-learn	KMeans, PCA, StandardScaler, silhouette_score
matplotlib	Graphiques de l'Elbow Method, scatter plots des clusters
seaborn	Visualisations statistiques, heatmap des centroïdes
joblib / pickle	Sauvegarde des modèles entraînés (KMeans, PCA, Scaler)

6. Résultats et impact

100%	4-6	>70%	0.5+
Clients segmentés	Clusters identifiés	Variance expliquée ACP	Score silhouette

6.1 Valeur business

- Budget marketing optimisé : concentration des efforts sur les segments Champion et Fidèles (80% de la valeur).
- Campagnes ciblées : messages personnalisés par segment (réactivation pour À Risque, onboarding pour Nouveaux).
- Meilleure rétention : identification précoce des clients à risque avant leur départ définitif.
- ROI marketing amélioré : élimination du gaspillage marketing sur les segments à faible valeur.

7. Livrables

- Notebook Segmentationdeclient.ipynb — pipeline complet commenté (EDA → préparation → K-Means → ACP → interprétation).
- Modèles sauvegardés : kmeans_model.pkl, pca_model.pkl, scaler.pkl.
- Fichier de sortie avec label de segment assigné à chaque client.
- Rapport de synthèse des profils segments pour les équipes marketing.